

INSTITUTO FEDERAL DO NORTE DE MINAS GERAIS
CAMPUS MONTES CLAROS
CURSO DE BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

**AVALIAÇÃO DA VIABILIDADE DE UM SISTEMA
DE IDENTIFICAÇÃO DE CHAMADAS FALSAS
EM CHAMADAS DE EMERGÊNCIA**

ROBERT CRISTIANO ALMEIDA VIANA
ORIENTADORA: LUCIANA BALIEIRO COSME

Montes Claros

Abril de 2019

ROBERT CRISTIANO ALMEIDA VIANA

**AVALIAÇÃO DA VIABILIDADE DE UM SISTEMA
DE IDENTIFICAÇÃO DE CHAMADAS FALSAS
EM CHAMADAS DE EMERGÊNCIA**

Projeto de Monografia apresentado ao Curso de Graduação em Ciência da Computação do Instituto Federal do Norte de Minas Gerais – Campus Montes Claros, como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação.

ORIENTADORA: LUCIANA BALIEIRO COSME

Montes Claros

Abril de 2019

“If it wasn’t hard, everyone would do it. It’s the hard that makes it great”
(Tom Hanks)

Resumo

Palavras-chave: Inteligência Artificial, Classificação de texto, Redes Neurais, Processamento de Linguagem Natural.

Abstract

Keywords: Artificial Intelligence.

Sumário

Resumo	vii
Abstract	ix
Lista de Figuras	xiii
Lista de Tabelas	xv
1 Introdução	1
1.1 Motivação	2
1.2 Objetivos	3
1.3 Estrutura do trabalho	3
2 Conceitos Básicos	5
2.1 Classificação de dados	5
2.1.1 Grafos	6
2.1.2 Redes neurais artificiais	7
2.1.3 K-vizinhos mais próximos	9
2.2 Processamento de linguagem natural	10
2.2.1 Classificação de texto	11
3 Trabalhos Relacionados	13
3.1 Classificadores de texto	13
3.2 Chamadas emergenciais falsas: Problemas e Soluções	14
3.3 Privacidade dos dados e ética	17
4 Metodologia	19
4.1 Base de dados	19
4.2 Cronograma de atividades	20
Referências Bibliográficas	21

Lista de Figuras

2.1	Processo de classificação de flores do gênero Iris	6
2.2	Diagrama do Grafo G	7
2.3	Diagrama de um neurônio artificial	8
2.4	Ilustração do algoritmo K-vizinhos mais próximos aplicado em um plano cartesiano	9

Lista de Tabelas

2.1	Função incidência ψ de G	7
3.1	Lista de códigos traduzidos do MPDS.	16
4.1	Tabela de atributos que descrevem uma ocorrência da base de dados <i>Call</i> <i>Data</i>	20

Capítulo 1

Introdução

Com o objetivo de ampliar, regulamentar e aumentar a eficiência dos serviços de urgência no Brasil, o Ministério da Saúde publicou duas portarias em 2003, a GM/MS nº 1863 e a GM/MS nº 1864 que instituíram, respectivamente, a Política Nacional de Atenção às Urgências e o componente pré-hospitalar móvel, por meio da implantação do Serviço de Atendimento Móvel de Urgência (SAMU), disponível através do número telefônico 192, como também os serviços de urgência associados, em todo o território nacional (Brasil, 2003a,b). A implantação desses projetos mostrou grandes impactos positivos (Vieira & Mussi, 2008; Machado et al., 2011; Minayo & Deslandes, 2008).

Contudo, também surgiram novos problemas e desafios. Um dos principais problemas encontrados são as chamadas falsas ou trotes, no qual o indivíduo entra em contato com a unidade de atendimento e relata uma situação inexistente, que se não identificada pelo atendente, pode resultar em deslocamentos desnecessários de unidades e de recursos ao local do chamado. Outra situação comum, são as chamadas com categorização não emergencial, em que a população procura por orientações, tais como números de outros serviços, locais e endereços.

O grande problema dessas ligações é que elas ocupam a linha emergencial e consomem recursos, gerando transtornos e custos para os serviços de emergência. Este é um fator tão preocupante que, pode ocorrer a possibilidade da escassez total desses recursos em chamadas não emergenciais e caso haja outra pessoa que realmente necessite de atendimento, consequentemente não poderá receber os auxílios necessários a tempo e ir a óbito, em um grave acidente de trânsito, por exemplo.

Além desses riscos, uma mobilização indevida de recursos, sejam eles de pessoas, viaturas, ambulâncias, carros de combate a incêndio e, principalmente, de tempo, geram também prejuízos financeiros ao Estado. E esses recursos que poderiam ser investidos em outros setores, como educação, infraestrutura, segurança ou aperfeiçoamento dos próprios serviços de emergência, por exemplo, acabam tendo que ser remanejados.

O ato do trote aos serviços de emergência é um crime previsto no Código Penal brasileiro. Segundo o Art. nº 340 do Código Penal (Brasil, 1940), "Provocar a ação de autoridade, comunicando-lhe a ocorrência de crime ou de contravenção que sabe não se ter verificado", quando identificado o autor, o mesmo pode ser detido por um período de um a seis meses ou multado. Com uma análise cautelosa ao artigo, percebe-se que o mesmo não abrange a comunicação falsa de situações de emergência que motivem o acionamento do Serviço de Atendimento Móvel de Urgência (SAMU) ou corpo de bombeiros, e sim somente nos casos em que há relato de infrações penais. Como relatado por Peixoto et al. (2015), existem outros artigos e projetos de leis que poderiam ajudar a punir tal ato, mas devido a sua natureza, talvez não sejam a melhor opção para o problema.

Embora que, grande parte dos autores de chamados falsos são crianças e adolescentes, o problema se encontra em chamadas falsas iniciadas por adultos, pois o conteúdo dessas mensagens tendem a serem mais próximas de uma ocorrência real. Dificultando assim, a identificação de ser uma chamada falsa pelo atendente.

Após consultas na literatura disponível, não foram encontrados muitos resultados que visam identificar tais chamadas emergenciais falsas. O que leva a crer que, por ser uma área com pouca visibilidade, exista outros fatores que influenciem tão baixo investimento em pesquisas e soluções. Um desses fatores é que o conteúdo dessas ligações são sensíveis a privacidade e sujeitos a análise por um conselho de ética (Francisconi & Goldim, 1998). Sendo essa, uma barreira e um processo burocrático, porém necessário para o desencadeamento de pesquisas. Além disso, os gestores (responsáveis pelos dados) podem se sentir menos dispostos a disponibilizar dados anônimos para pesquisas devido a falta de divulgação de resultados positivos.

Existem poucas bases de dados públicas disponíveis para realizações de experimentos e prova de metodologias, que seriam capazes de solucionar tal problema. E ainda dentre tais bases, a maioria está disponível no idioma inglês, e os dados que são disponibilizados são rasos, carecendo de detalhes e proporcionando pouco espaço para uma exploração aprofundada.

1.1 Motivação

Segundo um estudo apontado pela Consultoria Legislativa do Senado, estima-se que o custo gerado por trotes aos serviços de emergência no Brasil, tais como o Serviço de Atendimento Móvel de Urgência (SAMU), Corpo de Bombeiros (CB) e Polícia Militar (PM), chega a R\$ 1 bilhão por ano. Esse levantamento foi apurado pela PM do estado do Amapá, onde eles avaliaram que a cada deslocamento para um atendimento

emergencial incompleto, gera um custo aproximado de R\$ 500 (G1, 2014; Peixoto et al., 2015).

Devido à proporção do problema, os atendentes do Centro Integrado de Operações de Segurança Pública (CIOSP) do governo de Mato Grosso, responsáveis estes pelo atendimento e despacho das chamadas emergenciais, receberam uma capacitação para identificar suspeitas de trote. Mesmo que não seja possível bloquear todas ligações indevidas, a triagem ajuda a amenizar os prejuízos (Araújo, 2016).

Diante desse cenário, que possui poucas pesquisas, visibilidade, resultados e também o não uso de técnicas computacionais para auxiliar os serviços de emergência, surge então, a possibilidade do levantamento de requisitos que seriam necessários para a construção de sistemas computacionais que auxiliem na identificação correta de chamadas falsas nos serviços de emergência. Busca-se ainda, motivar as autoridades envolvidas no processo, para que, invistam no desenvolvimento dessas ferramentas.

1.2 Objetivos

Ao final, deseja-se, mostrar a viabilidade de produzir sistemas capazes de identificação de chamadas falsas, como também produzir documentos e argumentos para que os gestores desses serviços possam avaliar a possibilidade de liberação do acesso aos dados reais e completos das chamadas, sem prejuízo ou violação de privacidade e com o retorno de uma ferramenta de apoio a decisão aos operadores. Com a conclusão da avaliação, também será possível elencar quais dados podem ser suficientes ou necessários para a identificação.

Como objetivos específicos alcançam-se:

- Pesquisar o uso de técnicas computacionais que possam auxiliar os serviços de atendimento de emergência;
- Apontar como métodos de classificação de dados, junto ao processamento de linguagem natural possa viabilizar a construção de sistemas que auxiliem a identificação de chamadas falsas;
- Motivar, com resultados positivos, as autoridades responsáveis, para aumentar o investimento no desenvolvimento de ferramentas;

1.3 Estrutura do trabalho

O restante deste trabalho está organizado na seguinte estrutura:

- No capítulo 2 são apresentados conceitos básicos relacionados a classificação de dados, processamento de linguagem natural e classificação de texto. Além disso, dois algoritmos de classificação de texto são descritos, as redes neurais artificiais e o k-vizinhos mais próximos.
- No capítulo 3 é apresentado uma revisão na literatura, abordando os problemas gerados por chamadas falsas, como também tentativas e soluções propostas para reduzir o impacto consequente. É abordado também sobre algoritmos de classificação de texto, com o objetivo de compreender suas vantagens, capacidades e eficiência, quando aplicados em contextos diferentes ou semelhantes ao deste trabalho.
- No capítulo 4 é apresentado a metodologia proposta para alcançar os objetivos especificados, como também uma descrição da base de dado que será utilizada e o cronograma de atividades esperadas para a próxima etapa.

Capítulo 2

Conceitos Básicos

Nesta seção, será explorado alguns fundamentos básicos para compreender, passo a passo, como será conduzida a metodologia proposta. Primeiramente introduz-se o problema da classificação de dados. Logo após esse conceito, descreve-se brevemente sobre uma abstração matemática muito utilizada na computação, o Grafo, que têm como serventia facilitar a visualização de como é composta a estrutura de um neurônio artificial, apresentada esta junto ao K-vizinhos mais próximos, como exemplos de técnicas de categorização de dados. Por fim, é apresentada uma introdução ao Processamento de Linguagem Natural (PLN), dando ênfase um sub-conceito muito valioso para os objetivos deste trabalho, que é classificação de texto.

2.1 Classificação de dados

Classificação de dados é um problema que abrange numerosas aplicações em diversos tipos de cenários no nosso dia a dia, tais como diagnóstico de doenças, identificação de objetos em fotos e vídeos, categorização de seres vivos e espécies, dentre outros. Esse problema é um dos tópicos mais ativos na área de aprendizado de máquina. Isso se dá, porque classificar dados consiste em determinar um rótulo ou classe para um objeto, baseado em um conjunto de características extraídas do mesmo (Duda et al., 1973; Bishop, 2006).

Em geral, dados são classificados como pertencentes a uma única classe ou categoria. Essa forma de classificação é denominada classificação de rótulo único. Por outro lado, se houver mais uma forma de rotular a mesma entrada, então dá-se o nome de classificação de multi-rótulo.


Formalmente o processo de classificação consiste em $X = \{X_1, \dots, X_i\}$ um conjunto de i entradas, $C = \{c_1, \dots, c_n\}$ um conjunto de n classes, tal que $n \geq 2$, e $Y = \{(X_1, \{c_1, \dots, c_j\}), \dots, (X_i, \{c_n, \dots, c_k\})\}$ um conjunto de treinamento, no qual cada

entrada X_i é categorizada por uma ou mais classes c_i . O objetivo geral de um classificador é aprender, através de seu conjunto de treinamento Y , uma possível correlação entre os atributos das entradas com suas classes, de tal forma que para uma entrada $X' = \{X'_1, \dots, X'_i\}$ que não possua rótulo c qualquer, seja possível classificar-lá.

Para ilustrar o processo de classificação de dados, considere o problema da flor de Iris. Nesse problema, existe um conjunto de flores do gênero Iris que podem ser rotuladas de uma das três maneiras: do tipo setosa, virgínica ou versicolor. Partindo desse ponto, o objetivo é determinar a qual grupo uma determinada flor pertence baseado nas medidas de sépalas e pétalas da mesma. A Figura 2.1 ilustra o processo de classificação. Inicialmente as informações específicas sobre as sépalas e pétalas devem ser extraídas em um pré-processamento. Em seguida tais medidas são processadas e suas características extraídas. Por fim, é realizada a classificação das flores. Neste exemplo os valores de X serão as medidas de comprimento, largura das sépalas e pétalas e C assumirá os rótulos setosa, virgínica e versicolor.

Em geral, existem diversos algoritmos para classificação de dados, onde cada um possui sua especificidade, vantagens e desvantagens. Neste trabalho, aborda-se o uso de duas técnicas para classificação de dados, sendo elas RNA e KNN.

Figura 2.1. Processo de classificação de flores do gênero Iris



Fonte: Pacheco (2016)

2.1.1 Grafos

Muitas situações no mundo real podem ser descritas com o uso de um diagrama, composto por um conjunto de pontos e arestas, onde as arestas unem pares desses pontos. Por exemplo, os pontos podem representar cidades em um mapa, e as arestas representariam as estradas que ligam duas cidades. O conceito de grafo parte de uma abstração matemática para caracterizar situações com essas características (Bondy & Murty, 1976).


Matematicamente um grafo G é uma tripla (V, E, ψ) , consistido por um conjunto não vazio de vértices V , um conjunto de arestas E e uma função de incidência ψ que caracteriza quais vértices possuem uma relação (através de uma aresta) com outros vérti-

ces. Por exemplo, seja $G = (V, E, \psi)$ um grafo (Figura 2.2), tal que $V = \{0, 1, 2, 3, 4, 5\}$, $E = \{a, b, c, d, e, f, g, h, i\}$ e ψ a função incidência representada na Tabela 2.1.

Tabela 2.1. Função incidência ψ de G

$\psi_a = 1, 2$
$\psi_b = 2, 0$
$\psi_c = 1, 0$
$\psi_d = 4, 3$
$\psi_e = 4, 5$
$\psi_f = 5, 3$
$\psi_g = 2, 5$
$\psi_h = 1, 4$
$\psi_i = 3, 0$

Figura 2.2. Diagrama do Grafo G



Fonte: Graph Online (2015).

Segundo Bondy & Murty (1976), os grafos possuem esse nome porque eles possuem uma representação gráfica, e são essas representações que facilitam o entendimento de suas propriedades. De fato, o grafo é uma ferramenta poderosa para simplificação e entendimento de problemas, possibilitando uma modelagem computacional e assim contribuindo com a resolução dos mesmos. Além disso, muitas outras técnicas se beneficiam quando aplicadas utilizando o conceito de grafos, tal como as Redes Neurais Artificiais.

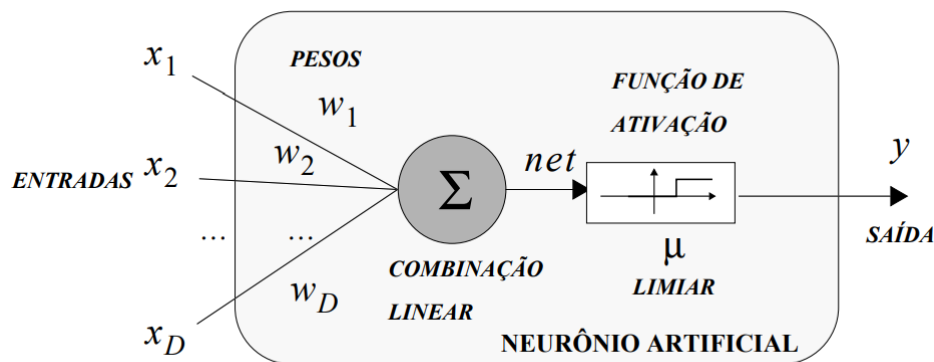
2.1.2 Redes neurais artificiais

O ser humano possui capacidades cognitivas extraordinárias e, desde o surgimento da computação, desejou-se projetar máquinas capazes de realizar tarefas inteligentes que,

até então, somente eram executadas por humanos. Os primeiros trabalhos desenvolvidos nessa área foram: um neurônio apresentado por McCulloch & Pitts (1943), usado posteriormente como base para a concepção do *Perceptron* por Rosenblatt (1958) e um neurônio chamado *Adaline* por Widrow & Hoff (1960). Tais trabalhos deram origem ao conceito de RNA que, em outras palavras, é uma tentativa de copiar a estrutura e o funcionamento do cérebro, composto este por bilhões de neurônios, para uma estrutura artificial, transformando assim as redes neurais biológicas em redes neurais artificiais (Rauber, 2005).

Para compreender o conceito por trás de uma rede neural, é preciso introduzir um modelo simplificado de um neurônio e suas capacidades de processamento associadas. Cada neurônio é considerado como uma unidade básica de processamento que, quando estimulada por sinais de entrada, emite sinais de saída como uma reação. Tais sinais emitidos por um neurônio, são repassados para outros neurônios através de uma conexão sináptica. Tal processo pode ser repetido por várias camadas de neurônios até chegar ao nosso cérebro, que então processa essa informação e produz novas reações (Baeza-Yates et al., 1999). A principal função de uma rede neural é armazenar conhecimento experimental e torná-lo disponível, o que em prática significa que este conhecimento é adquirido e armazenado em pesos sinápticos durante o processo. Uma RNA é normalmente implementada através de um programa de computador (*software*) ou através de componentes eletrônicos (*hardware*).

Figura 2.3. Diagrama de um neurônio artificial



Fonte: Rauber (2005)

Uma rede neural pode ser representada matematicamente através de uma estrutura de grafo (Figura 2.3), em que os vértices fazem o papel dos neurônios e as arestas representam as conexões sinápticas entre os neurônios, no qual se adicionarmos pesos a tais arestas, é possível mensurar a força de tal conexão sináptica. Seja x_i entradas fornecidas por outros neurônios para um neurônio artificial. O processamento desse


neurônio consiste em uma combinação linear das D entradas tais que $\sum_{i=1}^D w_i x_i$, onde x_i é uma aresta com peso w_i . Se tal valor ultrapassar um limiar μ , esse neurônio dispara um valor positivo (1) na saída binária y , caso contrário dispara um valor negativo (0) na saída.

Por ser uma ferramenta poderosa e possuir uma grande capacidade de processamento, possibilita diversas aplicações para diversas áreas do aprendizado de máquina, como classificação, clusterização, predição e regressão de dados.

2.1.3 K-vizinhos mais próximos

O algoritmo K-vizinhos mais próximos (do inglês: *K-nearest neighbours* - KNN) tem como objetivo determinar o rótulo de classificação de uma amostra, baseando-se em outras amostras vizinhas, advindas de um conjunto de treinamento. O classificador KNN, um dos mais simples algoritmos de classificação, é baseado em instâncias. Esse algoritmo encontra os k objetos mais similares e realiza uma votação de acordo com as classes às quais pertencem esses k objetos, assinalando por fim, uma classe ao objeto de teste. A literatura apresenta diversas formas para expressar essa distância/similaridade dentre os objetos de análise (Fukunaga & Narendra, 1975; Duda et al., 1973). Por exemplo, se os dados trabalhados estão em formato de texto, é comum utilizar a similaridade por cossenos. Por outro lado, se os dados possuírem formato numérico, possivelmente a distância euclidiana será mais eficaz.

Figura 2.4. Ilustração do algoritmo K-vizinhos mais próximos aplicado em um plano cartesiano



Fonte: Elaborado pelo autor

Na Figura 2.4, é ilustrado o processo de classificação com o algoritmo KNN. Neste exemplo, têm-se três classes, anteriormente conhecidas, sendo elas: classe A (círculo

vermelho), classe B (triângulo azul) e classe C (quadrado verde). O objetivo é identificar, por similaridade, a qual classe pertence a amostra (estrela cinza), olhando para os seus k vizinhos mais próximos. Para $k = 1$, esse algoritmo classificaria a amostra como pertencente a classe C. Por outro lado, se o valor escolhido para k é 5, por votação majoritária, a amostra seria classificada como pertencente a classe B.

Um grande fator que pode definir a eficácia do algoritmo KNN no contexto em que é aplicado, é o valor de escolha para o k . Por ser um valor variável (não constante), deve ser determinado de forma empírica, variando de acordo com a base de dados. Caso o valor escolhido para k seja muito baixo, a classificação ficará sujeita a *outliers*, ou seja, dados atípicos ou ruídos, que não condizem com o contexto da classificação. Já por outro lado, se k assumir um valor alto, a vizinhança poderá incluir elementos pertencentes a outras classes, não necessariamente relevantes ao objeto de análise, interferindo assim, no resultado final da rotulação (Fukunaga & Narendra, 1975). Por ser um fator relevante, deverá ser avaliado cuidadosamente.

2.2 Processamento de linguagem natural

O processamento de linguagem natural (PLN) têm como objetivo tratar os mais diversos aspectos presentes dentro da comunicação humana, tais como sons, palavras, sentenças e discursos, levando em consideração os seus formatos, referências, estruturas, significados, contextos e aplicações. Embora exista outros animais que possuem um vocabulário com centenas de sinais, tais como os elefantes e os golfinhos, somente os seres humanos possuem a capacidade de se comunicar, de forma confiável, em um número ilimitado de mensagens qualitativamente diferentes, sobre um tema qualquer (Russell & Norvig, 1994; Gonzalez & Lima, 2003).

Hoje em dia, com o constante crescimento da rede mundial de computadores, possibilitou o acesso a inúmeras páginas de informações na *Web*, no qual quase todas elas estão em um formato de linguagem natural. Entretanto, disponibilidade não significa fácil acesso à informação. Para uma máquina adquirir tal conhecimento, ela precisa ser treinada, de forma exaustiva, para compreender as complexas, e muitas vezes ambíguas, linguagens em que os seres humanos se comunicam.

Segundo Russell & Norvig (1994), as linguagens naturais, tais como o português e o espanhol, não podem ser caracterizadas como um conjunto de sentenças definitivas, pois de acordo com o contexto em que for definida uma sentença de alguma dessas linguagens, ela pode possuir inúmeras interpretações diferentes. Portanto, convém definir um modelo de linguagem natural como uma distribuição de probabilidade sobre sentenças. Existe um famoso ditado popular brasileiro que diz "para um bom entende-

dor, meia palavra basta", o que pode ser comumente aplicado para nós humanos, que possuímos uma espécie de dispositivo de especialização para aquisição de linguagens (Chomsky, 2014). Já que meia palavra basta, pode-se concluir que uma sentença de uma linguagem natural não é sempre aleatória, e que sim possui algum grau de previsibilidade e correlação entre a escolha das palavras. Portanto, nos leva a acreditar que palavras similares estejam presentes no mesmo contexto.

O PLN consiste no emprego de um conjunto de técnicas computacionais para aprender, entender e reproduzir uma linguagem natural. No processo de tradução do significado, tratamento de ambiguidade e entre outros desafios, o PLN pode utilizar de conhecimentos linguísticos e métodos estatísticos para resolvê-los. Por exemplo, considere uma análise sobre dois textos semelhantes A e B, no qual desconfia-se que exista possibilidade de plágio. Com o uso de um pré-processamento, seria possível filtrar os textos para remover *Stopwords*, que são palavras funcionais, tais como artigos, preposições e conetivos, que quando analisadas individualmente não possuem grande relevância para o contexto. Após o pré-processamento, é possível aplicar um método da distância mínima de edição, que como o próprio nome diz, significa quantas operações de inserções, remoções ou substituições de caracteres são necessárias para que o texto A torne-se o texto B, ou vice-versa. Uma das tarefas possíveis no PLN é a classificação de texto. Para compreender melhor o processo de aplicação de conhecimentos linguísticos para essa tarefa, é apresentado a seguir uma seção sobre classificação de texto.

2.2.1 Classificação de texto

Segundo Aggarwal (2014) um dos principais desafios encontrados durante o processo de classificação de texto é sobre o tamanho dos dados tratados, que podem variar de algumas poucas dezenas para milhões de palavras. Esses dados se encontram, quase sempre, de maneira esparsa, ou seja, possuindo baixa frequência de uso. Por outro lado, têm-se muitas vezes uma alta frequência de dados não úteis para tratamento, como as *Stopwords*.

É comum também, dependendo do contexto ou de como obteve-se o texto, que exista palavras com o mesmo significado, erros ortográficos ou até mesmo erros de codificação. Logo, muitas vezes é necessário uma etapa de normalização do texto. Normalizar um texto significa, segundo (Martin & Jurafsky, 2009), convertê-lo de forma conveniente à um formato padrão, que facilite as manipulações sobre os dados. Exemplos de sub-etapas da normalização são: *tokenization* e *lemmatization*.

Na *tokenization*, deseja-se separar as palavras contidas em um texto, de maneira que elas fiquem isoladas. Por exemplo, na frase "fui ao Rio de Janeiro", resultaria em 5 *tokens* distintos: "fui", "ao", "Rio", "de", "Janeiro". Contudo, uma separação

em *tokens* por somente o uso do espaçamento em branco, nem sempre representa o contexto da frase, pois como no exemplo "fui ao Rio de Janeiro", Rio de Janeiro não deve ser tratado como três *tokens* distintos, e sim como um único *token*, que no caso representa a cidade ou estado brasileiro. Em algumas linguagens naturais, nem todas palavras possuem espaço entre si, como é o caso do mandarim da China, por exemplo, dificultando ainda mais o processo de *tokenization*.

A etapa de *lemmatization*, é o processo, efetivamente, de deflexionar uma palavra para determinar o seu lema. Por exemplo, as palavras gato, gata, gatos, gatas são todas formas do mesmo lema: gato. Igualmente, as palavras estudou, estudava, estudaria, estudará, são do mesmo lema: estudar. A lematização é útil quando deseja-se ver os usos de palavras em contextos sem importância das flexões, como também para a criação e uso de índices ou na investigação linguística.

Além de uma etapa de normalização dos dados, uma etapa para extração e seleção de características é essencial, e pode gerar benefícios como: redução da dimensão do problema, que por sua vez aumenta a velocidade de execução do algoritmo; redução na quantidade total de características; aumento na precisão de predição e acerto; e facilitar a visualização dos dados.

Uma vez escolhido um conjunto de características, é possível aplicar algumas técnicas de classificação de texto, inclusive duas das que já foram abordadas aqui, as redes neurais artificiais e o k-vizinhos mais próximos, nos quais apresentam uma precisão superior a 98% quando aplicados ao problema de identificação de *e-mail spam* (Russell & Norvig, 1994).

A classificação ou categorização de texto é a tarefa de, dado algum tipo de texto, decidir a qual conjunto predefinido de classes o mesmo pertence. Por exemplo, decidir a qual linguagem pertence uma sentença ou identificar se um texto de uma chamada de emergência é falsa ou não, são exemplos de classificação de texto.

Capítulo 3

Trabalhos Relacionados

Neste capítulo, será apresentado trabalhos e pesquisas existentes na área que visão solucionar parcialmente ou completamente o problema de identificação de chamadas emergenciais falsas. Um trabalho soluciona parcialmente o problema, se o mesmo dispor alguma metodologia útil para resolver o problema geral. Como por exemplo técnicas de classificação de dados eficientes para texto, ou algum processamento de linguagem natural que facilite a seleção das características relevantes. Primeiramente apresenta-se ...

3.1 Classificadores de texto

Algoritmos de classificação de texto vêm sido aplicados com sucesso em vários diferentes problemas e em diversas áreas de atuação e interesse, tais como rotulação de conteúdos, produtos, multimídia; Gerenciamento de Relacionamento com o Cliente (do inglês: *Customer Relationship Management* - CRM) para empresas; monitoramento de conteúdo e tendências em redes sociais, dentre outros (Uysal & Gunal, 2012; Gupta, 2018). Alguns exemplos desses algoritmos são: Árvore de decisão, Máquina de Vetores de Suporte (do inglês: *Support Vector Machine* - SVM), RNA e KNN.

Em uma consulta preliminar na literatura disponível, não foram identificados trabalhos e pesquisas que utilizem de algoritmos de classificação de texto para identificação de chamados falsos. Portanto, uma revisão dos principais algoritmos de classificação de texto aplicados a outros contextos é feita a seguir.

Uysal & Gunal (2012) propuseram uma nova metodologia para extração de características em bases de dados textuais. E com o objetivo de avaliar a eficácia do novo método, executaram uma sequência de testes em quatro diferentes bases de dados, contendo estas diferentes características, com diferentes medidas de avaliação, junto ao uso de algoritmos de categorização de texto, como Árvore de decisão, SVM e RNA. Os

resultados desse novo método foram promissores, apresentando alto índice de acurácia e o menor tempo de execução dentre os outros métodos de extração de características comparados. Dentre os resultados obtidos, os métodos RNA e SVM se destacaram diante à Árvore de decisão em quase todos os testes, com taxas de precisão superiores a 90%. Mais precisamente, o método RNA apresentou melhores resultados quando foi aplicado junto as bases de dados de *e-mail spam* e textos *Short Message Service* (SMS). Ressaltando assim, o potencial e a eficácia do uso da RNA para interpretação de linguagem natural.

O uso do SVM para classificação de texto foi proposto por Joachims (1998). Em sua publicação, Joachims identificou que os textos em geral possuem: um alto volume de dados, com várias características distintas; baixo índice de características irrelevantes ou inúteis para serem eliminadas; e são linearmente separáveis. Analisando essas características ele deduziu que, qualquer algoritmo de classificação que trabalhe bem nessas circunstâncias, também conseguiria classificar eficientemente um texto. E para validar sua hipótese, Joachims experimentou a eficácia do algoritmo SVM para classificação de texto utilizando as bases de dados ModApte e Ohsumed *corpus*, quando comparado ao lado de métodos, até então, consolidados na literatura, como Naive Bayes, algoritmo de Rocchio, KNN e C4.5. Como resultados do experimento, obteve-se sucesso, visto que em média, o SVM acertou corretamente o *target* em 86% dos testes, superando todos os outros. Mais precisamente: Bayes (72%), Rocchio (79,9%), C4.5 (79.4%) e KNN (82.3%).

3.2 Chamadas emergenciais falsas: Problemas e Soluções

Chamadas emergenciais falsas são consideradas um fardo para os serviços emergenciais. Tais chamadas são responsáveis por perda de tempo, esforço, energia, recursos, enfim um ônus para o Estado.

Segundo Waseem et al. (2010), em uma análise feita sobre os dados das chamadas emergenciais recebidas entre outubro de 2004 e Maio de 2010, em Punjab, Paquistão, realçou que 97,85% foram identificadas como falsas, onde, mais precisamente, 91,5% destas foram identificadas como trote (brincadeiras ou insultos ao atendente); 7,27% por busca de informações não relacionadas ao serviço; 1,5% de chamadas por engano (discagem de número errado); e 0,14% de chamadas onde o solicitante forjou a necessidade de um atendimento emergencial. Diante do exposto, ações foram efetivadas: a implantação de um sistema de monitoramento de chamadas e um sistema de bloqueio de chamadas, no qual após três ou quatro chamadas falsas ou trotes originadas do

mesmo número, o bloqueio da linha telefônica seria realizado, impossibilitando assim, a efetuação de chamadas temporariamente. Entretanto, observa-se que as medidas propostas não obtiveram grande êxito, uma vez que não houve redução significativa da incidência dessas chamadas indevidas.

Rashford & Isoardi (2010), destacam a importância da otimização e do uso apropriado do sistema de chamadas emergenciais, combatendo os falsos chamados. Os autores realçam o desgaste financeiro que tal prática resulta na sociedade, retirando recursos que poderiam ser aproveitados em pacientes que realmente necessitam desse atendimento e transporte. Como medida preventiva, campanhas públicas de conscientização foram elaboradas, mas novamente não obtiveram os resultados esperados. Resultando assim, a introdução de penas mais severas, na legislação vigente da Austrália, para quem realizasse falsos chamados, podendo ser multado em até \$ 10.000 ou 1 ano de prisão. Ainda sobre a descrição dos serviços de ambulância no referido país, é relatado o uso do Sistema de Prioridades para Despacho Médico (do inglês: *Medical Priority Dispatch System* - MPDS). Neste sistema, o atendente é orientado a efetuar uma série de perguntas ao solicitante, com o objetivo de obter uma melhor descrição da emergência. Após essa triagem primária, a situação é então manualmente classificada em um código alfanumérico previamente definido, composto por: um número, entre 1 a 33 (Tabela 3.1), que descreve o principal sintoma identificado; uma letra, *Alpha*, *Beta*, *Charlie*, *Echo* ou *Omega*, que classifica a prioridade da emergência; e por fim, um outro número, que procura especificar ainda mais o problema. Este método, bem como outros métodos similares, foram elaborados com o objetivo de alcançar um padrão comum, reduzindo o critério subjetivo e pessoal dos atendentes sobre a situação do paciente. Há dados que denotam a eficiência destes métodos, onde é possível obter mais informações sobre o estado do paciente, aumentando assim a chance de sobrevivência, prestando um atendimento mais específico e eficiente (Gray & Walker, 2008).

Os estudiosos relatam ainda que as chamadas menos prioritárias devem ainda passar por uma segunda triagem, sendo esta, por médicos especialistas, com o objetivo de um diagnóstico mais preciso. Sendo possível, mudar o prognóstico anterior, aumentando o nível de prioridade ou até mesmo não efetivando o despacho da ambulância ao local e sim o desencadeamento de medidas alternativas para o atendimento (Marks et al., 2002; Gray & Walker, 2008). Embora que é demonstrado alguma eficiência e otimização no processo, tais métodos ainda são efetuados manualmente pelos operadores. Não sendo aproveitado assim, do uso de ferramentas computacionais que automatizem e facilitem este processo.

Devido ao alto índice de trotes recebidos por serviços de telefonia mundial, tal como o serviço de Operador de Chamadas Internacionais (do inglês: *International Operator*

Tabela 3.1. Lista de códigos traduzidos do MPDS.

Códigos MPDS			
1	Dor abdominal	18	Dor de cabeça
2	Reação alérgica	19	Problema no coração
3	Mordida por animal	20	Exposição a calor ou frio
4	Assalto	21	Hemorragia
5	Dor nas costas	22	Acidente industrial
6	Dificuldade para respirar	23	Overdose
7	Queimadura	24	Gravidez
8	Exposição a elemento químico perigoso	25	Problema psiquiátrico
9	Ataque cardíaco	26	Doença
10	Dor no peito	27	Esfaqueamento ou tiro
11	Asfixia	28	Acidente vascular
12	Convulsão	29	Acidente de trânsito
13	Diabete	30	Traumatismo
14	Afogamento	31	Indivíduo inconsciente
15	Eletrocussão	32	Sintoma não identificado
16	Problema ocular	33	Cuidado paliativo
17	Queda		

Direct Calling - IODC), que têm como função conectar um turista em um viagem internacional, através de uma chamada, com um atendente de seu país natal. Kuroiwa et al. (2004) propuseram um sistema de identificação automática de trotes e chamadas falsas, baseado na tecnologia de reconhecimento de fala. Esse sistema foi desenvolvido para operar com base em ligações para o Japão, onde é verificado se a pessoa que deseja utilizar do serviço, compreende bem o idioma japonês. O teste é validado solicitando o usuário a repetir uma palavra em japonês, esperando um determinado tempo pela pronuncia. Caso o usuário pronuncie corretamente a palavra, pressupõem-se que o mesmo conhece o dialeto da região o qual está telefonando, portanto as chances de ser uma ligação real são altas, sendo assim, o usuário é rapidamente redirecionado para o atendente. Caso contrário, uma segunda e última tentativa de pronuncia é solicitada ao usuário. Se o mesmo errar ou não pronunciar a palavra, um aviso é dado e a ligação é encerrada. Como resultados da metodologia proposta, os autores informaram que depois de analisar cerca de 100.000 chamadas, um total de 9489 foram identificadas

como chamadas reais, apresentando uma taxa de acerto de 97% e um taxa de rejeição de chamadas falsas de 93%. O volume de trotes eram tão alto que houve dias na semana em que a quantidade ultrapassava 6.000 de ligações rejeitadas. Contudo, apesar dos ótimos resultados apresentados pelos autores, esta aplicação é restrita ao contexto de chamadas internacionais e, ainda mais precisamente, específica e possível de ser implantada somente em alguns países, tal como o Japão, onde foi conduzido o estudo. Neste sentido, carece ainda o uso de uma ferramenta automatizada para ser aplicada no contexto do Brasil, por exemplo.

3.3 Privacidade dos dados e ética

Das bases de dados disponíveis, os conteúdos apresentam-se limitados, ou seja, com poucas informações, o que pode dificultar as pesquisas sobre o tema. Tal limitação denota especialmente no aspecto à privacidade dos dados, uma vez que, por serem sigilosos, não podem ser compartilhados de forma a expor os indivíduos envolvidos.

A garantia da preservação do segredo das informações, além de uma obrigação legal contida na maioria dos Códigos de Ética profissional e também no Código Penal Brasileiro (Brasil, 1940), é um dever *prima facie* de todos e para com todos. Além do conteúdo sigiloso presente, faz-se necessário a efetivação de uma etapa referente a Ética:

Nas atividades de pesquisa, muitas vezes são utilizados dados constantes em prontuários e bases de dados. Essa utilização deve ser resguardada e permitida apenas para projetos previamente aprovados por um Comitê de Ética em Pesquisa, desde que plenamente descaracterizada a identificação do paciente, inclusive quanto as suas iniciais e registro hospitalar. Mesmo nas publicações científicas não deve ser possível identificar os pacientes através de fotografias ou outras imagens. Em caso de necessidade imperiosa, isto será permitido apenas com o consentimento, por escrito, dos mesmos o que possui amparo na própria Constituição Federal, em seu Art. 5º, item X. (Francisconi & Goldim, 1998).

Entretanto como apontado por Francisconi & Goldim (1998), existem situações que claramente constituem exceções à preservação de segredos, devido ao risco de vida associado ou ao benefício social que pode ser obtido. Se tratando de uma área com poucas pesquisas realizadas, existem poucos resultados que comprovem a possível eficácia de um sistema que solucione a identificação correta de chamadas falsas em serviços de emergência. E conseqüentemente, os gestores que administram tais dados se sentem menos propensos a contribuir com pesquisas, por desconhecer o potencial que tais ferramentas poderiam oferecer ao processo.

Em suma, é fundamental compreender o respeito e o devido cuidado que todas as informações dos usuários desses serviços emergenciais merecem, como também o desenvolvimento de estratégias para tratar-las de forma eticamente adequada.

Capítulo 4

Metodologia

4.1 Base de dados

A base de dados a ser trabalhada neste projeto é a *Call Data*, do centro de comunicações do departamento de polícia de Seattle (*Seattle Police Department Communications Center* - SPD), dos Estados Unidos da América. Esta base de dados representa os relatórios das chamadas emergenciais originados pela comunidade local, onde é armazenado cerca de 95% de todos os chamados recebidos pelo departamento. No total, estão disponíveis 11 colunas de informações que descrevem a ocorrência (Tabela 4.1). Existindo mais de 3,9 milhões ocorrências únicas registradas desde 6 de fevereiro de 2009. Novos dados são inseridos diariamente pela equipe administradora, o que é um ponto positivo, pois é possível estimar o número de chamadas falsas recebidas em relação ao número total de chamados nos últimos anos, como também validar os objetivos ressaltados neste trabalho no cenário atual.

Por se tratar de uma base de dados pública e disponível na internet, as informações disponíveis são restritas em relação aos dados originais que são coletados diariamente pelo departamento, pois devido a sua natureza, são informações sigilosas e privadas da comunidade local. Dados como: nome, idade, sexo ou logradouro da ocorrência, foram removidos pelos administradores com o objetivo de preservar a privacidade dos envolvidos.

Outra característica dessa base de dados é que ela está disponível no idioma inglês e com informações e relatórios dos chamados já bem resumidos, o que não possibilita tanta exploração e uso de técnicas de processamento de linguagem natural. Contudo, como toda base de dados, um pré-processamento é necessário, com objetivo de eliminar ou corrigir erros de ortografia, ambiguidades e informações irrelevantes.

Tabela 4.1. Tabela de atributos que descrevem uma ocorrência da base de dados *Call Data*.

Atributo	Descrição	Formato
ID	Identificador único	Texto
Registro	Como foi resolvido o chamado	Texto
Chamada	Origem da chamada (telefone, 911, alarme)	Texto
Prioridade	Prioridade assimilada ao chamado	Texto
Classificação inicial	Como foi classificado inicialmente a ocorrência	Texto
Classificação final	Como foi classificada pós o acompanhamento	Texto
Data e hora	Data e hora em que foi recebida o chamado	Data e hora
Tempo de chegada	Tempo de chegada do primeiro policial ao local do registro	Texto
Ponto cardeal	Ponto cardeal em relação ao mapa geográfico da cidade	Texto
Setor	Setor do ponto cardeal da ocorrência	Texto
Quadra	Quadra do setor da ocorrência	Texto

4.2 Cronograma de atividades

Referências Bibliográficas

- Aggarwal, C. C. (2014). *Data classification: algorithms and applications*. CRC press.
- Araújo, L. (2016). Trotes prejudicam serviços de emergência e dão prejuízo ao Estado. Disponível em <http://www.mt.gov.br/-/4135140-trotes-prejudicam-servicos-de-emergencia-e-dao-prejuizo-ao-estado>. Acesso em 23 de Junho de 2019.
- Baeza-Yates, R.; Ribeiro-Neto, B. et al. (1999). *Modern information retrieval*, volume 463. ACM press New York.
- Bishop, C. M. (2006). *Pattern recognition and machine learning*. springer.
- Bondy, J. A. & Murty, U. S. R. (1976). *Graph Theory with Applications*. Elsevier, New York.
- Brasil (1940). Decreto-Lei nº 2.848, de 7 de dezembro de 1940. Código Penal. Diário Oficial da União, Rio de Janeiro, 31 dez. 1940.
- Brasil (2003a). Portaria GM/MS n. 1863, de 29 de setembro de 2003. institui a política nacional de atenção às urgências, a ser implantada em todas as unidades federadas, respeitadas as competências das três esferas de gestão. Diário Oficial da União, Brasília, 6 out. 2003.
- Brasil (2003b). Portaria GM/MS n. 1864, de 20 de setembro de 2003. institui o componente pré-hospitalar móvel da política nacional de atenção às urgências, por intermédio da implantação do serviço de atendimento móvel de urgência em municípios e regiões de todo o território brasileiro: SAMU-192. Diário Oficial da União, Brasília, 6 out. 2003.
- Chomsky, N. (2014). *Aspects of the Theory of Syntax*, volume 11. MIT press.
- Duda, R. O.; Hart, P. E. et al. (1973). *Pattern classification and scene analysis*, volume 3. Wiley New York.

- Francisconi, C. F. & Goldim, J. R. (1998). Aspectos bioéticos da confidencialidade e privacidade. *Costa SIF, Oselka G, Garrafa V, coordenadores. Iniciação à bioética. Brasília: CFM*, pp. 269–84.
- Fukunaga, K. & Narendra, P. M. (1975). A branch and bound algorithm for computing k-nearest neighbors. *IEEE Transactions on Computers*, C-24(7):750–753.
- G1 (2014). No amapá, trotes ao 190 geram um custo R\$ 55 milhões, diz polícia militar. Disponível em <http://g1.globo.com/ap/amapa/noticia/2014/12/no-amapa-trotes-ao-190-geram-um-custo-r-55-milhoes-diz-policia-militar.html>. Acesso em 23 de Junho de 2019.
- Gonzalez, M. & Lima, V. L. (2003). Recuperação de informação e processamento da linguagem natural. In *XXIII Congresso da Sociedade Brasileira de Computação*, volume 3, pp. 347–395.
- Graph Online (2015). An online project aimed at creation and easy visualization of graph and shortest path searching. Disponível em <https://graphonline.ru/en/?graph=Cayleygraph>. Acesso em 13 de Maio de 2019.
- Gray, J. & Walker, A. (2008). Ampds categories: are they an appropriate method to select cases for extended role ambulance practitioners? *Emergency Medicine Journal*, 25(9):601–603.
- Gupta (2018). Text Classification: Applications and Use Cases. Disponível em <https://towardsdatascience.com/text-classification-applications-and-use-cases-beab4bfe2e62>. Acesso em 02 de Julho de 2019.
- Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. In *European conference on machine learning*, pp. 137–142. Springer.
- Kuroiwa, S.; Naito, M.; Nakamura, M.; Sakayori, S. & Mukasa, T. (2004). Automatic prank call rejection system for home country direct based on speech recognition technology. *Electronics and Communications in Japan (Part II: Electronics)*, 87(4):44–52.
- Machado, C. V.; Salvador, F. G. A. F. & O'Dwyer, G. (2011). Serviço de Atendimento Móvel de Urgência no Brasil: análise da política nacional. *Revista de Saúde Pública*, 45:519 – 528.

- Marks, P.; Daniel, T.; Afolabi, O.; Spiers, G. & Nguyen-Van-Tam, J. (2002). Emergency (999) calls to the ambulance service that do not result in the patient being transported to hospital: an epidemiological study. *Emergency Medicine Journal*, 19(5):449–452.
- Martin, J. H. & Jurafsky, D. (2009). *Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition*. Pearson/Prentice Hall Upper Saddle River.
- McCulloch, W. S. & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, 5(4):115–133.
- Minayo, M. C. d. S. & Deslandes, S. F. (2008). Análise da implantação do sistema de atendimento pré-hospitalar móvel em cinco capitais brasileiras. *Cadernos de Saúde Pública*, 24:1877 – 1886.
- Pacheco, A. G. C. (2016). Agregação de classificadores neurais via integral de choquet com respeito a uma medida fuzzy. Master's thesis, Programa de Pós-Graduação em Informática.
- Peixoto, M.; Sousa, R. A. F. & Odon, T. I. (2015). Combate ao trote telefônico: uma questão de emergência.
- Rashford, S. & Isoardi, K. (2010). Optimizing the appropriate use of the emergency call system, and dealing with hoax callers. *Emergency Medicine Australasia*, 22(5):366–367.
- Rauber, T. W. (2005). Redes neurais artificiais. *Universidade Federal do Espírito Santo*.
- Rosenblatt, F. (1958). The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*, 65(6):386.
- Russell, S. J. & Norvig, P. (1994). *Inteligência artificial*. Pearson Educación.
- Uysal, A. K. & Gunal, S. (2012). A novel probabilistic feature selection method for text classification. *Knowledge-Based Systems*, 36:226–235.
- Vieira, C. M. S. & Mussi, F. C. (2008). A implantação do Projeto de atendimento Móvel de Urgência em Salvador/BA: panorama e desafios. *Revista da Escola de Enfermagem da USP*, 42:793 – 797.
- Waseem, H.; Durrani, M. & Naseer, R. (2010). Prank calls: a major burden for an emergency medical service. *Emergency Medicine Australasia*, 22(5):480–480.

Widrow, B. & Hoff, M. E. (1960). Adaptive switching circuits. Technical report, Stanford Univ Ca Stanford Electronics Labs.